SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 1337

Obrada podataka tehnologijom Apache Spark

Martin Matak

Zagreb, svibanj 2016.

Umjesto ove stranice umetnite izvornik Vašeg rada.
Da bi ste uklonili ovu stranicu obrišite naredbu `\izvornik`. Na ovoj stranici se

nalazi izvornik.

Zahvala - TODO . . . :)

SADRŽAJ

1. Uvod

1.1. Motivacija

Skoro pa svaka osoba danas posjeduje mobilni uređaj, a neke osobe posjeduju i više njih. Pametni mobilni uređaji postaju neizostavan dodatak svakog modernog čovjeka. Prošlo je vrijeme kada su mobilni uređaji jedino služili za pozive i SMS poruke. Današnji mobilni uređaji imaju puno više mogućnosti. Osim što je zadržana funkcionalnost uspostavljanja poziva i slanja poruka, postoji mogućnost povezivanja na internet, orijentaciju u prostoru, mjerenje brzine itd. Da bi sve te stvari bile moguće, većina današnjih mobilnih uređaja u sebi sadrži senzore koji su navedeni i opisani u tablici 1.1.

Pretpostavimo da je mobilni uređaj spojen na internet i da svakih nekoliko sekundi pošalje vrijednost koju u tom trenutku mjeri pojedini senzor. U samo jednom danu može se skupiti dosta podataka. A što kada to ne bi radili za jedan uređaj nego za sve izdane uređaje nekog modela? Količina podataka bi jako brzo narasla.

Kako količina podataka postaje sve veća, dolazimo do pojma *Velika količina podataka* (engl. *Big Data*). U današnje vrijeme postoji više podataka u digitalnom obliku nego što ih je ikada bilo. Jedan od zanimljivijih izazova je kako ih djelotvorno obraditi i zaključiti nešto iz toga, odnosno kako od te velike količine podataka doći do nekih pametnih zaključaka i nešto novo naučiti.

Tehnologija *Apache Spark* je tehnologija otvorenog koda (engl. *open source*) koja omogućava pisanje programa za obradu podataka u tri programskih jezika: *Java*, *Python* i *Scala*. Dodatno, postoji i mogućnost interaktivnog rada.
U okviru ovog rada proučeni su neki djelovi ove tehnologije, razrađeno nekoliko konkretnih primjera obrade podataka te ostvarena programska rješenja koja obavljaju tu obradu koristeći tehnologiju *Apache Spark*.

Svi primjeri su napisani u programskom jeziku *Java*.

Tablica 1.1: Neki od senzora u današnjim mobilnim uređajima.

Senzor	Opis
Akcelerometar	Elektromehanička komponenta koja mjeri sile ubrzanja.
Barometar	Mehanički senzor za mjerenje atmosferskog pritiska (na trenutnoj lokaciji uređaja).
Senzor svjetlosti	Mjeri intenzitet, tj. jačinu svjetlosti i uglavnom se nalazi s prednje strane uređaja, iznad ekrana.
Senzor blizine	U stanju prepoznati situacije kada mu neki objekt stoji u blizini - ovo omogućava automatske pozive prilikom primicanja telefona licu uz zaključavanje telefona da bi onemogućili slučajno prekidanje poziva uhom ili slično.
Senzor gestikulacije	Prepoznaje kretnje ruke tako što detektira infracrvene zrake koje se reflektiraju, odnosno omogućuje djelomično upravljanje telefonom bez doticanja ekrana.
Žiroskop	Uređaj koji se koristi za navigaciju i mjerenje kutne brzine.
Geomagnetski senzor	Mjeri okolno geomagnetsko polje za sve tri fizičke osi, odnosno služi kao kompas na mobilnim uređajima.
Hall Sensor	Magnetski senzor zadužen za prepoznavanje je li maska telefona zatvorena ili otvorena.

1.2. Osnovni gradivni elementi

Tehnologija *Apache Spark* je pisana u programskom jeziku *Scala* i izvršava se na *Javinom virtualnom stroju* (engl. *Java Virtual Machine, kratica JVM*). Instalacija na osobno računalo je objašnjena u dodatku A. Opisi nekih direktorija i datoteka koje se dobiju instalacijom dani su u tablici 1.2. Zanimljivo je spomenuti da postoji interaktivna ljuska *Spark shell*, ali isključivo za programske jezike *Python* i *Scala*. Datoteke u direktoriju *bin* služe upravo za to. Budući da je ovaj rad ograničen isključivo na programski jezik *Java*, a u ovom trenutku takva interaktivna ljuska još ne postoji, interaktivna ljuska nije detaljnije obrađena. Više informacija potražiti u TODO: REF-

ERENCA.

Tablica 1.2: Dio datoteka i direktorija dobivenih instalacijom.

Datoteka ili direktorij	Opis
bin	Sadrži izvršive datoteke koje se koriste za interaktivni rad s tehnologijom *Apache Spark*.
core, streaming, python, ...	Sadrži glavne komponente tehnologije.
README.md	Sadrži kratke instrukcije za upoznavanje s tehnologijom.
examples	Sastoji se od nekoliko jednostavnih primjera koje pomažu korisniku da se uhoda i što bezbolnije nauči koristiti programsko sučelje koje tehnologija pruža.

Osnovna programska apstrakcija s kojom tehnologija *Apache Spark* radi je *otporni raspodijeljeni skup podataka* (engl. *resilient distributed dataset, kratica RDD*). To je skup podataka koji se nalazi na računalima (jednom ili više njih) i moguće ga je paralelno obrađivati. Tehnologija *Apache Spark* nudi bogato programsko sučelje za rad s tim skupovima podataka.

Tehnologija se sastoji od nekoliko ključnih elemenata koji su u tablici 1.3 samo nabrojani i opisani rečenicom ili dvije. Detaljnije objašnjenje nalazi se u kasnijim poglavljima. Slika 1.1 predstavlja osnovne elemente tehnologije *Apache Spark*.

Tablica 1.3: Dio datoteka i direktorija dobivenih instalacijom.

Komponenta	Opis
Spark SQL	Omogućuje rad s bilo kakvim strukturiranim podatcima, primjerice *JSON*. Također, nudi i mogućnost izvršavanja *SQL* naredbi.
Spark Streaming	Komponenta zadužena za rad s tokovima podataka.
MLib	Koristi se za postupak strojnog učenja.
GraphX	Biblioteka za obradu grafova (npr. graf prijatelja na društvenoj mreži).

Slika 1.1: Osnovni elementi tehnologije *Apache Spark*.

2. Prvi programi

U ovom poglavlju opisano je kako napisati osnovni program koristeći tehnologiju *Apache Spark*. Također je opisano i od čega se takav program sastoji i koja je uloga pojedine komponente programa. Primjer koji se obrađuje je primjer 2.1.2, a svodi se na jednostavan algoritam brojanja riječi.

2.1. Postavljanje temelja

2.1.1. Osnovni elementi aplikacije

Općenito govoreći, svaka se Spark aplikacija sastoji od nekoliko komponenata. Prva komponenta koju ćemo spomenuti je program koji se izvršava - onaj čija je `main` metoda pokrenuta, odnosno onaj koji pokreće obradu podataka. Taj program naziva se pozivajući program (engl. *driver*). Pozivajući program s podatcima priča kroz "tunel" koji se naziva *SparkContext*.

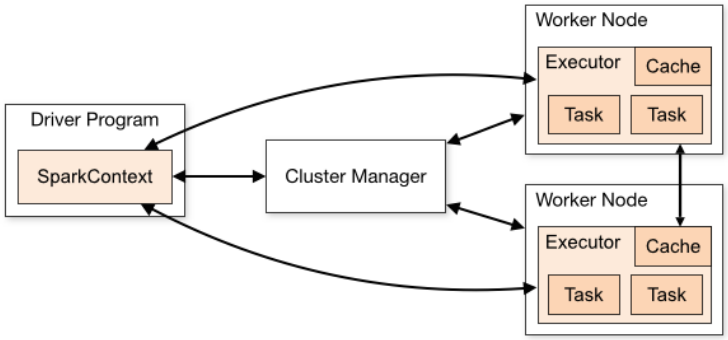

Slika 2.1: Prikaz elemenata aplikacije. Preuzeto s `http://spark.apache.org/docs/latest/cluster-overview.html`.

Budući da je tehnologija *Apache Spark* namijenjena za paralelnu obradu podataka, postoje još dvije komponente koje pridonose upravo tome. Pojedino računalo u *grozdu* (engl. *cluster*) naziva se *radnim čvorom* (engl. *worker node*), a proces koji se izvršava

na pojedinom računalu naziva se *radnik* (engl. *executor*). Dozvoljeno je da *radnici* međusobno komuniciraju. U cijeloj priči može, a i ne mora eksplicitno biti uključen *upravitelj grozdom* (engl. *cluster manager*). Opisana struktura prikazana je na slici 2.1.

2.1.2. Korištenje tehnologije Apache Spark kroz programski jezik Java

Kako bi mogli pisati Spark programe u programskom jeziku *Java*, potrebno je povezati svoju aplikaciju s `spark-core` artifaktom s Mavena. Za postavljanje i instalaciju Mavena konzultirati `https://maven.apache.org/install.html` i knjigu TODO: Referenca. Za vrijeme pisanja ovog rada, najnovija verzija Sparka je 1.6.1, a odgovarajuće Maven koordinate su:

```
groupId = org.apache.spark
artifactId = spark-core_2.10
version = 1.6.1
```

Odgovarajuća `pom.xml` datoteka nalazi se u dodatku B. Jednom kada je `pom.xml` datoteka namještena i projekt uspješno povezan sa `spark-core`, sve što je još potrebno jest inicijalizirati *SparkContext* i napisati prvu aplikaciju. U primjeru 2.1.2 nalazi se jednostavna aplikacija koja jedino što radi je broji koliko puta se pojedina riječ pojavljuje u tekstualnoj datoteci.

```
1  /**
2   *
3   */
4  package hr.fer.zemris;
5
6  import java.util.Arrays;
7
8  import org.apache.spark.SparkConf;
9  import org.apache.spark.api.java.JavaPairRDD;
10 import org.apache.spark.api.java.JavaRDD;
11 import org.apache.spark.api.java.JavaSparkContext;
12 import org.apache.spark.api.java.function.FlatMapFunction;
13 import org.apache.spark.api.java.function.Function2;
14 import org.apache.spark.api.java.function.PairFunction;
```

```
15
16 import scala.Tuple2;
17
18 /**
19  * Razred ima svrhu prikazati osnovnu funkcionalnost Spark
       tehnologije na
20  * primjeru prebrojavanja riječi u tekstualnoj datoteci. Kao
       rezultat program će
21  * zapisati u tekstualnu datoteku koja riječ se koliko puta
       ponavlja. Očekuje se
22  * dva argumenta kroz naredbeni redak, a to su putanja do
       tekstualne datoteke u
23  * kojoj treba izbrojati riječi i putanja do direktorija u
       koji će se zapisati
24  * rezultat.
25  *
26  * @author mmatak
27  *
28  */
29 public class BrojanjeRijeci {
30   /**
31    * Metoda koja se pokrene kada se pokrene program. Očekuje
         putanju do
32    * datoteke s riječima i putanju do direktorija gdje će
         zapisati rezultat
33    * izvođenja programa.
34    *
35    * @param args
36    *         Argumenti naredbenog retka.
37    */
38   @SuppressWarnings("serial")
39   public static void main(String[] args) {
40     String ulaznaDatoteka = args[0];
41     String izlazniDirektorij = args[1];
42
43     // inicijalizacija SparkContext-a
44     SparkConf conf = new SparkConf().setMaster("local")
45     .setAppName("Brojanje rijeci");
```

```
46      JavaSparkContext sc = new JavaSparkContext(conf);
47
48      // učitavanje podataka
49      JavaRDD<String> ulaz = sc.textFile(ulaznaDatoteka);
50
51      // razmak se koristi da bi razdvojio dvije riječi
52      JavaRDD<String> rijeci = ulaz.flatMap(new
            FlatMapFunction<String, String>() {
53        public Iterable<String> call(String redak) {
54          return Arrays.asList(redak.split(" "));
55        }
56      });
57
58      // transformiraj u parove (rijec,1) i broji
59      JavaPairRDD<String, Integer> brojRijeci = rijeci
60      .mapToPair(new PairFunction<String, String, Integer>() {
61        public Tuple2<String, Integer> call(String rijec) {
62          return new Tuple2<String, Integer>(rijec, 1);
63        }
64      }).reduceByKey(new Function2<Integer, Integer, Integer>()
            {
65        public Integer call(Integer x, Integer y) {
66          return x + y;
67        }
68      });
69
70      // spremi rezultat u izlaznu datoteku
71      brojRijeci.saveAsTextFile(izlazniDirektorij);
72      // zatvori "tunel" odnosno SparkContext
73      sc.close();
74    }
75  }
```

Primjer 2.1: Program koji broji koliko se puta koja riječ pojavljuje u datoteci.

Analizirajmo što smo napravili. Inicijalizirali smo *SparkContext* tako što smo rekli da se odvija na lokalnom računalu i zadali smo ime aplikacije. Zatim smo kreirali RDD iz tekstualne datoteke koja je predana kao argument naredbenog retka. Taj RDD

nam je poslužio za kreiranje novog RDD-a koji je nastao tako što smo svaki redak razdvojili po razmaku i kreirali uređeni par (*riječ*, 1). U tom uređenom paru nam *riječ* predstavlja ključ, a 1 predstavlja vrijednost. Odnosno, uređeni par je oblika (*ključ*, *vrijednost*). Zatim smo iz tako uređenih parova, one koji imaju jednaki ključ zbrojili po vrijednostima i u tom trenutku[1] nije više postojalo dva uređena para koji imaju jednake ključeve. Na kraju smo rezultat zapisali i eksplicitno zatvorili *SparkContext*. Kako je ovo bio početni primjer, *lambda* izrazi koji su uobičajeni za programski jezik *Java 8* nisu korišteni iz razloga da bi se lakše shvatilo što se sve treba implementirati. Odgovarajući kod koristeći lambda izraze dan je u primjeru 2.1.

```
// razmak se koristi da bi razdvojio dvije riječi
JavaRDD<String> rijeci = ulaz.flatMap(redak ->
   Arrays.asList(" "));

// transformiraj u parove (rijec,1) i broji
     JavaPairRDD<String, Integer> brojRijeci = rijeci
          .mapToPair(rijec -> new Tuple2<String,
             Integer>(rijec, 1))
          .reduceByKey((x, y) -> x + y);
```

Primjer 2.2: Brojanje riječi koristeći lambda izraze.

2.2. Programiranje s RDD-ovima

Resilient distributed dataset (RDD) je osnovna podatkovna struktura tehnologije Apache Spark. To je *nepromjenjiva* (engl. *immutable*) kolekcija podataka. To znači da se iz jednog RDD-a može jedino napraviti drugi RDD, a ne može se promijeniti postojeći RDD. U prethodnom primjeru to je vidljivo pri pozivu metode `flatMap`. Ta metoda transformira postojeći RDD `ulaz` u novi RDD `rijeci`. Sličnu transformaciju radi i metoda `mapToPair`. Drugim riječima, *transformacija* (engl. *transformation*) je svaka metoda koja iz jednog RDD-a kreira drugi RDD. Uz transformacije, postoje i *akcije* (engl. *actions*). Akcije se razlikuju od transformacija po tome što ne vraćaju novi RDD nego vraćaju jedan ili više elemenata iz nekog RDD-

[1] Nije zapravo u tom trenutku se ništa dogodilo nego tek nakon poziva metode `saveAsTextFile()`, ali o *lijenoj evaluaciji* (engl. *lazy evaluation*) će biti govora tek kasnije.

a, ili kao u primjeru 2.1.2, zapisuju RDD u obliku tekstualne datoteke - metoda `saveAsTextFile`.
U tablici 2.1 mogu se naći neke od mogućih transformacija i njihovi opisi, a u tablici 2.2 nalaze se akcije koje je moguće pozvati zajedno s odgovarajućim opisima.

Tablica 2.1: Neke od transformacija

Transformacija	Opis
`map(`*`func`*`)`	Vraća novi RDD nastao tako što je svaki element orginalnog RDD-a predan funckiji *func*.
`filter(`*`func`*`)`	Vraća novi RDD nastao tako što su iz orginalnog RDD-a preuzeti samo oni elementi za koje funkcija *func* vraća `true`.
`flatMap(`*`func`*`)`	Slično kao `map(`*`func`*`)`, ali jedan ulazni element kreira 0 ili više izlaznih elemenata.
`union(`*`drugiRDD`*`)`	Vraća uniju između RDD-a nad kojim je akcija pozana i RDD-a koji je predan kao argument.
`intersection(`*`drugiRDD`*`)`	Vraća presjek između RDD-a nad kojim je akcija pozana i RDD-a koji je predan kao argument.

Za opis ostalih transformacija, pogledati `http://spark.apache.org/docs/latest/programming-guide.html#transformations`.

Tablica 2.2: Akcije

Akcija	Opis
`reduce(`*`func`*`)`	Agregacija elemenata iz RDD-a tako što se nad dva elementa pozove funkcije *func*, a ta funkcija vrati jedan element. Funkcija *func* bi trebala biti komutativna i asocijativna kako bi se pravilno izvršavala u paralelnoj obradi podataka.
`collect()`	Vraća polje svih elemenata iz RDD-a direktno u *driver* program. Budući da je tih elemenata puno, u praksi se poziva nakon transformacije `filter()`.
`count()`	Vraća broj elemenata u RDD-u
`take(`*`n`*`)`	Vraća polje prvih *n* elemenata iz RDD-a.
`first()`	Vraća prvi element iz RDD-a. Može se ostvariti i pozivom metode `take(`*`1`*`)`

Za opis ostalih akcija, pogledati `http://spark.apache.org/docs/latest/programming-guide.html#actions`.

Budući da se radi o velikoj količini podataka, evaluacija transformacija je *lijena* (engl. *lazy evaluation*). To znači da Spark samo pamti koje sve transformacije treba napraviti nad RDD-ovima, ali ne i da ih odmah odradi. Sve potrebne transformacije budu napravljene tek pozivom prve akcije.
U nastavku slijedi primjer koji iz datoteke `logfile.txt` broji koliko puta je zahtjev bio na URL koji u sebi sadrži riječ "burza" i koliko je puta došao zahtjev na URL koji u sebi sadrži riječ "index". Njihova unija je također izračunata.

```
package hr.fer.zemris;

import org.apache.spark.SparkConf;
import org.apache.spark.api.java.JavaRDD;
import org.apache.spark.api.java.JavaSparkContext;

public class Primjer3 {
  public static void main(String[] args) {
    // inicijalizacija SparkContext-a
```

```
        SparkConf conf = new SparkConf().setMaster("local")
             .setAppName("Brojanje rijeci");
        JavaSparkContext sc = new JavaSparkContext(conf);

        // učitavanje podataka
        JavaRDD<String> ulaz = sc.textFile("logfile.txt");

        // transformacije
        JavaRDD<String> burze = ulaz.filter(redak ->
           redak.contains("burza"));
        JavaRDD<String> indexi = ulaz.filter(redak ->
           redak.contains("index"));
        JavaRDD<String> burzeUnijaIndexi = burze.union(indexi);

        // akcije
        long brojLinija = burzeUnijaIndexi.count();
        long ukupanBrojLinija = ulaz.count();
        System.out.println(
             "Broj linija koje sadrže riječ 'burza' ili 'index'
                je: "
                  + brojLinija + ", odnosno "
                  + (double) 100 * brojLinija / ukupanBrojLinija +
                     "%.");
        System.out.println(
             "Prva linija koja sadrži riječ 'burza' ili 'index'
                je: \n"
                  + burzeUnijaIndexi.first());
        sc.close();
    }
}
```

Primjer 2.3: Korištenje transformacija i akcija.

Ovdje imamo 4 RDD-a: `ulaz`, `burze`, `indexi` i `burzeUnijaIndexi`. RDD `burze` i RDD `indexi` su kreirani na temelju RDD-a `ulaz`. RDD `burzeUnijaIndexi` je kreiran na temelju RDD-a `burze` i na temelju RDD-a `indexi`. U nastavku je graf koji to opisuje.

Tek prilikom poziva akcije `burzaUnijaIndexi.count()` se zapravo kreira RDD

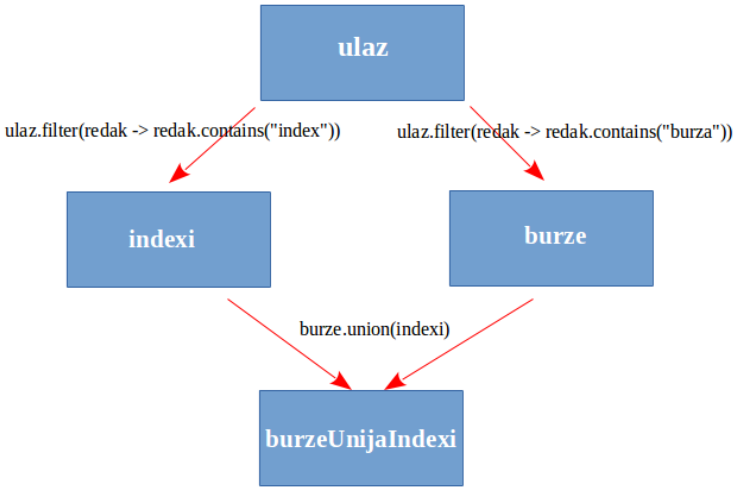

Slika 2.2: Transformacije nad RDD-ovima.

`ulaz`, na temelju njega RDD `burza` i RDD `indexi` i onda tek na temelju njih se kreira RDD `burzaUnijaIndexi` te se tek onda računa ukupni broj linija u tom RDD-u. Nakon što se to izračuna, svi RDD-ovi nestaju iz memorije. Prilikom poziva akcije `burzeUnijaIndexi.first()` **ponovno** se kreiraju prethodno navedeni RDD-i i sve ide iz početka.

Na prvi pogled ovo izgleda kao loša implementacija, ali budući da se ovdje radi o velikoj količini podataka i ne možemo ih nikako sve pohraniti u memoriju, ovo je zapravo logična implementacija. Ukoliko ne želimo svaki puta iz početka računati i kreirati RDD `burzaUnijaIndexi`, trebamo ga `perzistirati` pozivom metode `persist()` i predavanjem odgovarajućeg parametra (pogledati tablicu 2.3), odnosno spremiti ga u memoriju ili na disk. Ako ga imamo spremljenog, ne treba ga ponovno računati. Razine perzistencije dane su u tablici u 2.3.

Tablica 2.3: Razine perzistencije

Razina	Prostorno zauzeće	Procesorsko vrijeme	U memoriji	Na disku
`MEMORY_ONLY`	Visoko	Nisko	Da	Ne
`MEMORY_ONLY_SER`	Nisko	Visoko	Da	Ne
`MEMORY_AND_DISK`	Visoko	Srednje	Dio	Dio
`MEMORY_AND_DISK_SER`	Nisko	Visoko	Dio	Dio
`DISK_ONLY`	Nisko	Visoko	Ne	Da

3. Napredno programiranje

U ovom poglavlju opisane su neke napredne tehnike za rad s tehnologijom *Apache Spark*. Objašnjen je *PageRank* algoritam, a i dana je implementacija istog u primjeru 3.1.1.

3.1. Primjer: Analiza algoritma PageRank

3.1.1. Algoritam

Zanimljivo je pitanje kako je *Google* toliko dobar u rezultatima koje korisnik dobije na svoj upit, točnije, kako ispravno sortira po relevantnosti stranice od bolje prema lošijoj? Odgovor na to daje algoritam *PageRank* koji je dobio ime po jednom od osnivača *Google*-a, Larry Pageu. Ovo potpoglavlje započinje kroz analizu algoritma *PageRank*. U ovom radu iznesena je pojednostavljena verzija algoritma, a više informacija nalazi se na `https://en.wikipedia.org/wiki/PageRank`.
Algoritam mjeri koliko je koja stranica važna po tome koliko drugih stranica upućuje na nju. Ideja je jednostavna: što više stranica ima poveznicu na neku stranicu `N`, to je stranica `N` važnija i time bolje rangirana. U obzir se uzima i koja stranica pokazuje na stranicu `N` (je li to stranica na koju sve ostale stranice pokazuju ili je to neka stranica na koju nitko ne pokazuje) kao i na koliko ostalih stranica ta stranica sadrži poveznice (nije isto ako je na cijeloj stranici samo jedna poveznica i ako na cijeloj stranici ima 1000 poveznica). Stranice na koje neka stranica `M` ima linkove nazivamo *susjedima*.
Pojednostavljena izvedba algoritma je sljedeća:

1. Inicijalizira se rang svake stranice na 1.0.
2. Svaka stranica *n* svim svojim susjedima šalje doprinos `rang(`*n*`)/brojSusjeda(`*n*`)`.
3. Postavi ukupni rang stranice prema formuli: $0.15 + 0.85 *$ *ukupan primljeni doprinos*.

Posljednja dva koraka se odrade nekoliko puta kako bi se dobio što precizniji rezultat, u praksi je dovoljno desetak puta.
Implementacija algoritma dana je u primjeru 3.1.1.

```
1  package hr.fer.zemris.naprednoProgramiranje;
2
3  import java.util.ArrayList;
4  import java.util.List;
5
6  import org.apache.spark.SparkConf;
7  import org.apache.spark.api.java.JavaPairRDD;
8  import org.apache.spark.api.java.JavaRDD;
9  import org.apache.spark.api.java.JavaSparkContext;
10
11 import com.google.common.collect.Iterables;
12
13 import scala.Tuple2;
14
15 public class PageRankAlgoritam {
16   private static final String ULAZNA_DATOTEKA =
       "pageRankInput.txt";
17   private static final int BROJ_ITERACIJA = 10;
18
19   public static void main(String[] args) {
20
21     // Inicijalizacija SparkContext-a.
22     SparkConf conf = new SparkConf().setMaster("local")
23         .setAppName("Brojanje rijeci");
24     JavaSparkContext sc = new JavaSparkContext(conf);
25
26     // Učitavanje podataka.
27     JavaRDD<String> ulaz = sc.textFile(ULAZNA_DATOTEKA);
28
29     // Pročitaj sve ulazne URL-e i inicijaliziraj njihove
         susjede.
30     JavaPairRDD<String, Iterable<String>> linkovi = ulaz
31         .mapToPair(redak -> {
32           String[] elementi = redak.split("\\s+");
```

```
33            return new Tuple2<String, String>(elementi[0],
                  elementi[1]);
34          }).distinct().groupByKey().cache();
35      // Svaku vrijednost u orginalnom RDDu zamijeni s 1.0 i
           vrati novi RDD.
36      JavaPairRDD<String, Double> rangovi =
           linkovi.mapValues(value -> 1.0);
37
38      // iteracija 2. i 3. koraka algoritma
39      for (int i = 0; i < BROJ_ITERACIJA; i++) {
40        // za svaki link izracunaj njegovu doprinos drugim
             linkovima
41        JavaPairRDD<String, Double> doprinosi =
             linkovi.join(rangovi)
42              .values().flatMapToPair(linkoviRang -> {
43                int brojSusjeda = Iterables.size(linkoviRang._1);
44                List<Tuple2<String, Double>> rezultati = new
                     ArrayList<Tuple2<String, Double>>();
45                for (String susjed : linkoviRang._1) {
46                  rezultati.add(new Tuple2<String,
                         Double>(susjed,
47                          linkoviRang._2 / brojSusjeda));
48                }
49                return rezultati;
50              });
51        rangovi = doprinosi.reduceByKey((v1, v2) -> v1 + v2)
52              .mapValues(suma -> 0.15 + suma * 0.85);
53      }
54      // spremi u memoriju
55      List<Tuple2<String, Double>> rangoviFinal =
           rangovi.collect();
56      // ispis
57      for (Tuple2<String, Double> entry : rangoviFinal) {
58        System.out.println(
59              "URL " + entry._1 + "\tima vrijednost " +
                   entry._2);
60      }
61      sc.close();
```

```
62      }
63  }
```

Primjer 3.1: Algoritam *PageRank*.

3.1.2. Analiza algoritma

3.2. RDD-i kao uređeni parovi

3.3. Čitanje i spremanje podataka

3.4. Globalne varijable

4. Zaključak

Zaključak.

LITERATURA

[1] Službena dokumentacija projekta *Apache Spark* `http://spark.apache.org/docs/latest/`

[2] Holden Karau, Andy Konwinski, Patrick Wendell i Matei Zaharia *Learning Spark, lighting-fast*

[3] Marko Čupić, *Programiranje u Javi*, verzija 0.3.26

[4] Ivan Krišto, Boran Car, Mateja Čuljak, Vedrana Janković, Hrvoje Bandov *Upute za korištenje LaTeXpredloška za Završni i Diplomski rad te seminar*, godina 2010.

Appendices

A. Instalacija

Ovdje će biti prikazana instalacija na operacijskom sustavu *Ubuntu 15.10*. Ovo nije veliko ograničenje jer se iz ovih uputa može zaključiti i kako instalacija ide za neki drugi operacijski sustav.

Za početak je potrebno imati instaliranu Javu, a je li Java instalirana na računalu se može provjeriti tako što se u naredbenom retku unese sljedeća naredba:

`java -version`. Kao rezultat bi trebali dobiti trenutno instaliranu verziju Jave. Ukoliko Java nije instalirana, potrebno ju je najprije instalirati. Više informacija o instalaciji se može pronaći u TODO.

Jednom kada imamo instaliranu Javu, sve što treba napraviti je otići na službene stranice: `https://spark.apache.org/downloads.html`, odabrati najnoviju verziju (Za vrijeme pisanja ovog rada to je verzija *1.6.1 (Mar 09 2016*), izabrati odgovarajući paket te pokrenuti dohvaćanje odgovarajuće *.tgz* arhive. Najjednostavnije je odabrati neki *pre-built* paket, primjerice *Pre-built for Hadoop 2.6 and later*. Daljnji koraci instalacije su napisani pod pretpostavkom da je dohvaćena ta verzija paketa. Moguće je instalirati i *Source code* varijantu paketa, ali taj postupak instalacije ovdje nije opisan.

Nakon što je dohvaćena odgovarajuća arhivu, potrebno ju je raspakirati.

Raspakiranje arhive moguće je napraviti preko naredbe:

```
$ tar -xvf spark-1.6.1-bin-hadoop2.6.tgz
```

Nakon toga, dobra je praksa premjestiti instalaciju u neki prikladniji direktorij. Tako nešto može se napraviti na sljedeći način:

```
$ mv Downloads/spark-1.6.1-bin-hadoop2.6 faks/spark/
```

Ovim korakom je instalacija završena.

Kako bi bili sigurni da je instalacija uspješna, potrebno je pozicionirati se u *bin* direktorij te u terminalu upisati `./spark-shell`. Ispis bi trebao biti sličan ovome:

```
mmatak@martins-beast:~/faks/spark/bin$ ./spark-shell
Welcome to
      ____              __
     / __/__  ___ _____/ /__
    _\ \/ _ \/ _ `/ __/  '_/
   /___/ .__/\_,_/_/ /_/\_\ version 1.6.1
      /_/

Using Scala version 2.10.5 (OpenJDK 64-Bit Server VM, Java
    1.8.0_91)
Type in expressions to have them evaluated.
Type :help for more information.
scala>
```

Ukoliko se prikaže greška vezana uz *sqlContext*, to nije razlog za brigu. U ovom trenutku to nije važno. Radi ljepšeg formata ovog rada, u gornjem ispisu izbrisana su upozorenja (engl. *warnings*).

B. Postavljanje datoteke pom.xml

Datoteka koja je potrebna kako bi Maven ispravno dohvatio artifakt `spark-core` bi trebala izgledati slično kao što je dano u nastavku. Za ispravno funkcioniranje, trebala bi se zvati `pom.xml`.

```
<project xmlns="http://maven.apache.org/POM/4.0.0"
    xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
    xsi:schemaLocation="http://maven.apache.org/POM/4.0.0
    http://maven.apache.org/xsd/maven-4.0.0.xsd">
  <modelVersion>4.0.0</modelVersion>
  <groupId>hr.fer.zemris</groupId>
  <artifactId>Prvi-programi</artifactId>
  <version>0.0.1-SNAPSHOT</version>
  <name>Prvi programi</name>
  <description>Prvi programi u Spark-u</description>
  <dependencies>
   <dependency>
     <groupId>org.apache.spark</groupId>
     <artifactId>spark-core_2.10</artifactId>
     <version>1.6.1</version>
   </dependency>
  </dependencies>
</project>
```

Obrada podataka tehnologijom Apache Spark

Sažetak

Sažetak na hrvatskom jeziku.

Ključne riječi: Ključne riječi, odvojene zarezima.

Title

Abstract

Abstract.

Keywords: Keywords.