SVEUČILIŠTE U ZAGREBU FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 1337

Obrada podataka tehnologijom Apache Spark

Martin Matak

Zagreb, svibanj 2016.



Zahvala - TODO . . . :)

SADRŽAJ

1.	Uvo	d	1
	1.1.	Motivacija	1
	1.2.	Osnovni gradivni elementi	2
2.	Prvi	programi	5
	2.1.	Postavljanje temelja	5
		2.1.1. Osnovni elementi aplikacije	5
		2.1.2. Korištenje tehnologije Apache Spark kroz programski jezik Java	6
	2.2.	Otporni raspodijeljeni skup podataka	9
3.	Nap	redno programiranje	15
	3.1.	Primjer: Algoritam PageRank	15
		3.1.1. Upoznavanje s algoritmom	15
		3.1.2. Implementacija i analiza	21
	3.2.	Skupovi podataka kao uređeni parovi	25
	3.3.	Čitanje i spremanje podataka	27
	3.4.	Dijeljene varijable	27
		3.4.1. Odašiljatelji	28
		3.4.2. Akumulatori	31
4.	Zak	ljučak	34
Li	teratu	ıra	35
Do	datal	x A. Instalacija	37
Do	datal	x B. Postavljanje datoteke pom.xml	39

1. Uvod

1.1. Motivacija

Skoro pa svaka osoba danas posjeduje mobilni uređaj, a neke osobe posjeduju i više njih. Pametni mobilni uređaji postaju neizostavan dodatak svakog modernog čovjeka. Prošlo je vrijeme kada su mobilni uređaji jedino služili za pozive i SMS poruke. Današnji mobilni uređaji imaju puno više mogućnosti. Osim što je zadržana funkcionalnost uspostavljanja poziva i slanja poruka, postoji mogućnost povezivanja na internet, orijentaciju u prostoru, mjerenje brzine itd. Da bi sve te stvari bile moguće, većina današnjih mobilnih uređaja u sebi sadrži senzore koji su navedeni i opisani u tablici 1.1.

Pretpostavimo da je mobilni uređaj spojen na internet i da svakih nekoliko sekundi pošalje vrijednost koju u tom trenutku mjeri pojedini senzor. U samo jednom danu može se skupiti dosta podataka. A što kada to ne bi radili za jedan uređaj nego za sve izdane uređaje nekog modela? Količina podataka bi jako brzo narasla.

Kako količina podataka postaje sve veća, dolazimo do pojma *Velika količina podataka* (engl. *Big Data*). U današnje vrijeme postoji više podataka u digitalnom obliku nego što ih je ikada bilo. Jedan od zanimljivijih izazova je kako ih djelotvorno obraditi i zaključiti nešto iz toga, odnosno kako od te velike količine podataka doći do nekih pametnih zaključaka i nešto novo naučiti.

Tehnologija *Apache Spark* je tehnologija otvorenog koda (engl. *open source*) koja omogućava pisanje programa za obradu podataka u tri programskih jezika: Java, Python i Scala. Dodatno, postoji i mogućnost interaktivnog rada.

U okviru ovog rada proučeni su neki djelovi ove tehnologije, razrađeno nekoliko konkretnih primjera obrade podataka te ostvarena programska rješenja koja obavljaju tu obradu koristeći tehnologiju *Apache Spark*.

Svi primjeri su napisani u programskom jeziku Java.

Tablica 1.1: Neki od senzora u današnjim mobilnim uređajima.

Senzor	Opis
Akcelerometar	Elektromehanička komponenta koja mjeri sile
	ubrzanja.
Barometar	Mehanički senzor za mjerenje atmosferskog
	pritiska (na trenutnoj lokaciji uređaja).
Senzor svjetlosti	Mjeri intenzitet, tj. jačinu svjetlosti i uglavnom
	se nalazi s prednje strane uređaja, iznad ekrana.
Senzor blizine	U stanju prepoznati situacije kada mu neki ob-
	jekt stoji u blizini - ovo omogućava automatske
	pozive prilikom primicanja telefona licu uz za-
	ključavanje telefona da bi onemogućili slučajno
	prekidanje poziva uhom ili slično.
Senzor gestikulacije	Prepoznaje kretnje ruke tako što detektira in-
	fracrvene zrake koje se reflektiraju, odnosno
	omogućuje djelomično upravljanje telefonom
	bez doticanja ekrana.
Žiroskop	Uređaj koji se koristi za navigaciju i mjerenje
	kutne brzine.
Geomagnetski senzor	Mjeri okolno geomagnetsko polje za sve tri fiz-
	ičke osi, odnosno služi kao kompas na mobil-
	nim uređajima.
Hall Sensor	Magnetski senzor zadužen za prepoznavanje je
	li maska telefona zatvorena ili otvorena.

1.2. Osnovni gradivni elementi

Tehnologija *Apache Spark* je pisana u programskom jeziku Scala i izvršava se na *Javinom virtualnom stroju* (engl. *Java Virtual Machine*, kratica JVM). Instalacija na osobno računalo je objašnjena u dodatku A. Opisi nekih direktorija i datoteka koje se dobiju instalacijom dani su u tablici 1.2. Zanimljivo je spomenuti da postoji interaktivna ljuska *Spark shell*, ali isključivo za programske jezike Python i Scala. Datoteke u direktoriju *bin* služe upravo za to. Budući da je ovaj rad ograničen isključivo na programski jezik Java, a u ovom trenutku takva interaktivna ljuska još ne postoji, interaktivna ljuska nije detaljnije obrađena. Više informacija potražiti u [2].

Tablica 1.2: Dio datoteka i direktorija dobivenih instalacijom.

Datoteka ili direktorij	Opis		
bin	Sadrži izvršive datoteke koje se koriste za inter-		
	aktivni rad s tehnologijom Apache Spark.		
core, streaming, python,	Sadrži glavne komponente tehnologije.		
README.md	Sadrži kratke instrukcije za upoznavanje s		
	tehnologijom.		
examples	Sastoji se od nekoliko jednostavnih primjera		
	koje pomažu korisniku da se uhoda i što bezbol-		
	nije nauči koristiti programsko sučelje koje		
	tehnologija pruža.		

Osnovna programska apstrakcija s kojom tehnologija *Apache Spark* radi je *otporni raspodijeljeni skup podataka* (engl. *resilient distributed dataset*, kratica RDD) [4]. Atribut *otproni* znači da se može ponovno rekonstruirati u slučaju da se particija uništi. *Raspodijeljeni* znači da je to skup podataka koji se nalazi na računalima (jednom ili više njih) i moguće ga je paralelno obrađivati. *Skup podataka* znači da predstavlja nekakvu kolekciju podataka. Tehnologija *Apache Spark* nudi bogato programsko sučelje za rad s tim skupovima podataka.



Slika 1.1: Osnovni elementi tehnologije Apache Spark.

Tehnologija se sastoji od nekoliko ključnih elemenata koji su u tablici 1.3 samo nabrojani i opisani rečenicom ili dvije. Detaljnije objašnjenje nalazi se u kasnijim poglavljima. Slika 1.1 predstavlja osnovne elemente tehnologije *Apache Spark*.

Tablica 1.3: Dio datoteka i direktorija dobivenih instalacijom.

Komponenta	Opis		
Spark SQL	Omogućuje rad s bilo kakvim strukturiranim		
	podatcima, primjerice JSON. Također, nudi i		
	mogućnost izvršavanja SQL naredbi.		
Spark Streaming	Komponenta zadužena za rad s tokovima po-		
	dataka.		
MLib	Koristi se za postupke strojnog učenja.		
GraphX	Biblioteka za obradu grafova (npr. graf pri-		
	jatelja na društvenoj mreži).		

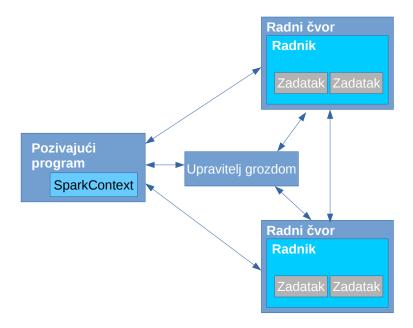
2. Prvi programi

U ovom poglavlju opisano je kako napisati osnovni program koristeći tehnologiju *Apache Spark*. Također je opisano i od čega se takav program sastoji i koja je uloga pojedine komponente programa. Primjer koji se obrađuje je primjer 2.1, a svodi se na jednostavan algoritam brojanja riječi.

2.1. Postavljanje temelja

2.1.1. Osnovni elementi aplikacije

Općenito govoreći, svaka se Spark aplikacija sastoji od nekoliko komponenata. Prva komponenta koju ćemo spomenuti je program koji se izvršava - onaj čija je main metoda pokrenuta, odnosno onaj koji pokreće obradu podataka. Taj program naziva se pozivajući program (engl. *driver*). Pozivajući program s podatcima priča kroz "tunel" koji se naziva *SparkContext*.



Slika 2.1: Prikaz elemenata aplikacije.

Budući da je tehnologija *Apache Spark* namijenjena za paralelnu obradu podataka, postoje još dvije komponente koje pridonose upravo tome. Pojedino računalo u *grozdu* (engl. *cluster*) naziva se *radnim čvorom* (engl. *worker node*), a proces koji se izvršava na pojedinom računalu naziva se *radnik* (engl. *executor*). Dozvoljeno je da *radnici* međusobno komuniciraju. U cijeloj priči može, a i ne mora eksplicitno biti uključen *upravitelj grozdom* (engl. *cluster manager*). Opisana struktura prikazana je na slici 2.1.

2.1.2. Korištenje tehnologije Apache Spark kroz programski jezik Java

Kako bi mogli pisati Spark programe u programskom jeziku Java, potrebno je povezati svoju aplikaciju s spark-core artefaktom s Mavena. Za postavljanje i instalaciju Mavena konzultirati https://maven.apache.org/install.html i knjigu [3]. Za vrijeme pisanja ovog rada, najnovija verzija Sparka je 1.6.1, a odgovarajuće Maven koordinate su:

```
groupId = org.apache.spark
artifactId = spark-core_2.10
version = 1.6.1
```

Odgovarajuća pom. xml datoteka nalazi se u dodatku B. Jednom kada je pom. xml datoteka namještena i projekt uspješno povezan sa spark-core, sve što je još potrebno jest inicijalizirati *SparkContext* i napisati prvu aplikaciju. U primjeru 2.1 nalazi se jednostavna aplikacija koja jedino što radi je broji koliko puta se pojedina riječ pojavljuje u tekstualnoj datoteci.

```
package hr.fer.zemris;

import java.util.Arrays;

import org.apache.spark.SparkConf;
import org.apache.spark.api.java.*;
import org.apache.spark.api.java.function.*;

import scala.Tuple2;

/**
```

```
* Razred ima svrhu prikazati osnovnu funkcionalnost Spark
   * tehnologije na primjeru prebrojavanja riječi
   * u tekstualnoj datoteci. Kao rezultat program će
   * zapisati u tekstualnu datoteku koja riječ se koliko puta
   * ponavlja. Očekuje se dva argumenta kroz naredbeni
   * redak, a to su putanja do tekstualne datoteke u kojoj
   * treba izbrojati riječi i putanja do direktorija
   * u koji će se zapisati rezultat.
   * @author mmatak
21
22
   */
  public class BrojanjeRijeci {
    /**
     * Metoda koja se pokrene kada se pokrene program.
     * Očekuje putanju do datoteke s riječima i putanju
     * do direktorija gdje će zapisati rezultat
     * izvođenja programa.
     * @param args
31
               Argumenti naredbenog retka.
     */
    @SuppressWarnings("serial")
    public static void main(String[] args) {
       if (args.length != 2) {
36
         System.out.println("Program očekuje 2 argumenta.");
       String ulaznaDatoteka = args[0];
       String izlazniDirektorij = args[1];
40
       // inicijalizacija SparkContext-a
       SparkConf conf = new SparkConf().setMaster("local")
43
       .setAppName("Brojanje rijeci");
44
       JavaSparkContext sc = new JavaSparkContext(conf);
       // učitavanje podataka
       JavaRDD<String> ulaz = sc.textFile(ulaznaDatoteka);
```

```
// razmak se koristi da bi razdvojio dvije riječi
       JavaRDD<String> rijeci = ulaz.flatMap(new
51
          FlatMapFunction<String, String>() {
         public Iterable<String> call(String redak) {
52
            return Arrays.asList(redak.split(" "));
       });
       // transformiraj u parove (rijec,1) i broji
       JavaPairRDD<String, Integer> brojRijeci = rijeci
58
       .mapToPair(new PairFunction<String, String, Integer>() {
         public Tuple2<String, Integer> call(String rijec) {
            return new Tuple2<String, Integer>(rijec, 1);
61
         }
       }).reduceByKey(new Function2<Integer, Integer, Integer>()
         public Integer call(Integer x, Integer y) {
64
            return x + y;
65
         }
       });
67
       // spremi rezultat u izlaznu datoteku
       brojRijeci.saveAsTextFile(izlazniDirektorij);
       // zatvori "tunel" odnosno SparkContext
       sc.close();
     }
```

Primjer 2.1: Program koji broji koliko se puta koja riječ pojavljuje u datoteci.

Analizirajmo što smo napravili. Inicijalizirali smo *SparkContext* tako što smo rekli da se odvija na lokalnom računalu i zadali smo ime aplikacije. Zatim smo kreirali RDD iz tekstualne datoteke koja je predana kao argument naredbenog retka. Taj skup podataka nam je poslužio za kreiranje novog skupa podataka koji je nastao tako što smo svaki redak razdvojili po razmaku i kreirali uređeni par (*riječ*, 1). U tom uređenom paru, koji je oblika (*ključ*, *vrijednost*), *riječ* nam predstavlja ključ, a 1 predstavlja vrijednost. Zatim smo iz tako uređenih parova, one parove koji imaju jednaki

ključ zbrojili po vrijednostima i u tom trenutku¹ nije više postojalo dva ili više uređena para koja imaju jednake ključeve. Na kraju smo rezultat zapisali i eksplicitno zatvorili *SparkContext*.

Kako je ovo bio početni primjer, *lambda* izrazi koji su uobičajeni za programski jezik *Java 8* nisu korišteni iz razloga da bi se lakše shvatilo što se sve treba implementirati. Odgovarajući kod koristeći lambda izraze dan je u primjeru 2.2.

Primjer 2.2: Brojanje riječi koristeći lambda izraze.

2.2. Otporni raspodijeljeni skup podataka

Otporni raspodijeljeni skup podataka (engl. resilient distributed dataset, kratica RDD) je osnovna podatkovna struktura tehnologije Apache Spark. To je nepromjenjiva, samo za čitanje (engl. immutable, read-only) kolekcija podataka. Iz toga proizlazi da se iz jednog skupa podataka može jedino napraviti drugi skup podataka, a ne može se promijeniti postojeći. U prethodnom primjeru to je vidljivo pri pozivu metode flatMap. Ta metoda transformira ulaz u rijeci. Sličnu transformaciju radi i metoda mapToPair. Drugim riječima, transformacija (engl. transformation) je svaka metoda koja iz jednog skupa podataka kreira novi skup. Uz transformacije, postoje i akcije (engl. actions). Akcije se razlikuju od transformacija po tome što ne vraćaju novi skup podataka nego prvenstveno služe za dohvat jednog ili više elemenata

¹U tom trenutku se ništa dogodilo nego tek nakon poziva metode saveAsTextFile(), ali *lijena* evaluacija (engl. lazy evaluation) opisana je tek kasnije.

iz nekog skupa. Dodatno, imaju mogućnost zapisivanja podataka kao što je prikazano u primjeru 2.1 - metoda saveAsTextFile.

U tablici 2.1 mogu se naći neke od mogućih transformacija i njihovi opisi, a u tablici 2.2 nalaze se akcije koje je moguće pozvati zajedno s odgovarajućim opisima.

Tablica 2.1: Neke od transformacija nad otpornim raspodijeljenim skupovima podataka.

Transformacija	Opis
map(func)	Vraća novi skup nastao tako što je svaki element
	orginalnog skupa predan funkciji func.
filter(func)	Vraća novi skup nastao tako što su iz orginalnog
	skupa preuzeti samo oni elementi za koje
	funkcija func vraća true.
flatMap(func)	Slično kao map (func), ali jedan ulazni ele-
	ment kreira 0 ili više izlaznih elemenata.
union(<i>drugiSkup</i>)	Vraća uniju između skupa nad kojim je trans-
	formacija pozvana i skupa koji je predan kao
	argument.
intersection(drugiSkup)	Vraća presjek između skupa nad kojim je trans-
	formacija pozvana i drugog skupa koji je predan
	kao argument.

Za detaljnije objašnjenje ovih i ostalih transformacija, pogledati http://spark.apache.org/docs/latest/programming-guide.html#transformations.

Budući da se radi o velikoj količini podataka, evaluacija transformacija je *lijena* (engl. *lazy evaluation*). To znači da Spark samo pamti koje sve transformacije treba napraviti nad skupovima, ali ne i da ih odmah odradi. Sve potrebne transformacije budu napravljene na zahtjev, odnosno tek pozivom prve akcije.

Tablica 2.2: Akcije primjenjive nad otpornim raspodijeljenim skupom podataka

Akcija	Opis
reduce (func)	Agregacija elemenata iz skupa tako što se nad
	dva elementa pozove funkcije func, a ta funkcija
	vrati jedan element. Funkcija func bi trebala biti
	komutativna i asocijativna kako bi se pravilno
	izvršavala u paralelnoj obradi podataka.
collect()	Vraća polje svih elemenata iz skupa direktno u
	pozivajući program. Budući da je tih elemenata
	puno, u praksi se poziva nakon transformacije
	filter().
count()	Vraća broj elemenata u skupu.
take(n)	Vraća polje prvih n elemenata iz skupa.
first()	Vraća prvi element iz skupa. Može se ostvariti
	i pozivom akcije take (1)

Za detaljnije objašnjenje ovih i ostalih akcija, pogledati http://spark.apache.org/docs/latest/programming-guide.html#actions.

U nastavku slijedi primjer 2.4 koji obrađuje datoteku logfile.txt. Jedan od redaka te datoteke dan je u primjeru 2.3 i iz toga se može zaključiti kako općenito izgleda redak datoteke logfile.txt.

```
89.164.244.106 - [24/Feb/2008:01:05:08] "GET /index.jsp?lang=hr HTTP/1.1" 200
```

Primjer 2.3: Korištenje transformacija i akcija.

Primjer 2.4 broji koliko puta je zahtjev bio na URL koji u sebi sadrži riječ "burza" i koliko je puta došao zahtjev na URL koji u sebi sadrži riječ "index". Njihova unija je također izračunata.

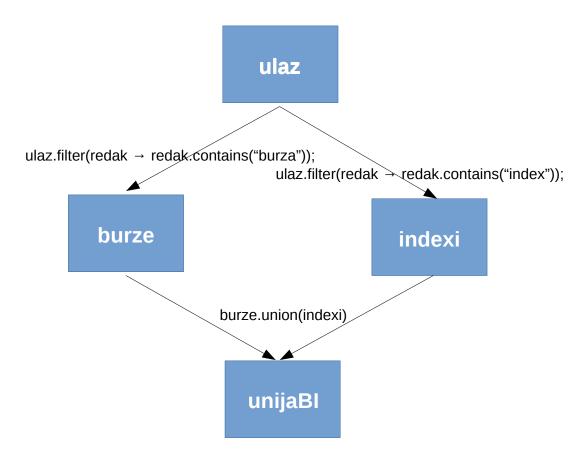
```
package hr.fer.zemris;
import org.apache.spark.SparkConf;
import org.apache.spark.api.java.JavaRDD;
import org.apache.spark.api.java.JavaSparkContext;
```

```
public class Primjer3 {
  public static void main(String[] args) {
    // inicijalizacija SparkContext-a
    SparkConf conf = new SparkConf().setMaster("local")
         .setAppName("Brojanje rijeci");
    JavaSparkContext sc = new JavaSparkContext(conf);
    // učitavanje podataka
    JavaRDD<String> ulaz = sc.textFile("logfile.txt");
    // transformacije
    JavaRDD<String> burze = ulaz.filter(
         redak -> redak.contains("burza")
      );
    JavaRDD<String> indexi = ulaz.filter(
         redak -> redak.contains("index")
      );
    JavaRDD<String> unijaBI = burze.union(indexi);
    // akcije
    long brojLinija = unijaBI.count();
    long ukupanBrojLinija = ulaz.count();
    System.out.printf(
         "Broj linija koje sadrže riječ 'burza' ili 'index'
          je: %d, odnosno %f%%.\n", brojLinija,
          (double) 100 * brojLinija / ukupanBrojLinija
          );
    System.out.printf(
         "Prva linija koja sadrži riječ 'burza' ili 'index'
         je: %s\n", unijaBI.first()
         );
    sc.close();
  }
}
```

Primjer 2.4: Korištenje transformacija i akcija.

Ovdje imamo 4 skupa podataka: ulaz, burze, indexi i burzeUnijaIndexi.

Skupovi podataka burze i indexi su kreirani na temelju skupa podataka ulaz, a unijaBI je kreiran na temelju burze i na temelju indexi. Na slici 2.2 nalazi se graf koji to opisuje.



Slika 2.2: Transformacije nad skupovima podataka.

Tek prilikom poziva akcije burzaUnijaIndexi.count() se zapravo kreira ulaz, na temelju njega burza i indexi i onda tek na temelju njih se kreira unijaBI. Iz unijaBI ukupni broj linija dohvati se pozivom unijaBI.count(). Nakon što se to izračuna, svi skupovi podataka nestaju iz memorije. Prilikom poziva akcije unijaBI.first() ponovno se kreiraju prethodno navedeni skupovi podataka i sve ide iz početka.

Na prvi pogled ovo izgleda kao loša implementacija, ali budući da se ovdje radi o velikoj količini podataka i ne možemo ih nikako sve pohraniti u memoriju, ovo je zapravo logična implementacija. Ukoliko ne želimo svaki puta iz početka računati i kreirati unijaBI, trebamo ga pohraniti pozivom metode persist () i predavanjem odgovarajućeg parametra. Tablica 2.3 sadrži usporedbu različitih parametara koji se mogu predati metodi persist ().

Iz tablice 2.3 očito je da postoje dvije osi usporedbe: spremanje na disk - spremanje

Tablica 2.3: Usporedba mogućih parametara za metodu persist ().

Razina	Prostorno zauzeće	Procesorsko vrijeme	U memoriji	Na disku
MEMORY_ONLY	Visoko	Nisko	Da	Ne
MEMORY_ONLY_SER	Nisko	Visoko	Da	Ne
MEMORY_AND_DISK	Visoko	Srednje	Dio	Dio
MEMORY_AND_DISK_SER	Nisko	Visoko	Dio	Dio
DISK_ONLY	Nisko	Visoko	Ne	Da

u memoriju i spremanje u serijaliziranom obliku - spremanje u neserijaliziranom obliku. Postoji i parametar MEMORY_AND_DISK koji prvo podatke sprema u memoriju dok se memorija ne napuni, a kada se napuni, ostatak podataka se sprema na disk. Ono što razlikuje parametre koji sadrže postfiks SER i one koji ga ne sadrže je to što parametri s postfiksom SER spremaju podatke u serijaliziranom obliku, a drugi ne.

3. Napredno programiranje

U ovom poglavlju opisane su neke napredne tehnike za rad s tehnologijom *Apache Spark*. Objašnjen je algoritam *PageRank*, a dana je i implementacija istog u primjeru 3.1.

3.1. Primjer: Algoritam PageRank

Zanimljivo je pitanje kako je *Google* toliko dobar u rezultatima koje korisnik dobije na svoj upit, točnije, kako ispravno sortira po relevantnosti stranice od važnije prema manje važnoj? Odgovor na to daje algoritam *PageRank* koji je dobio ime po jednom od osnivača *Googlea*, Larry Pageu. Ovo potpoglavlje analizira upravo algoritam *PageRank*. U nastavku je iznesena pojednostavljena verzija algoritma, a više informacija o samom algoritmu nalazi se na https://en.wikipedia.org/wiki/PageRank.

3.1.1. Upoznavanje s algoritmom

Algoritam računa koliko je koja stranica važna po tome koliko drugih stranica upućuje na nju. Ideja je jednostavna: što više stranica ima poveznicu na neku stranicu N, to je stranica N važnija i time bolje rangirana. U obzir se uzima i koja stranica pokazuje na stranicu N (je li to stranica na koju sve ostale stranice pokazuju ili je to neka stranica na koju nitko ne pokazuje) kao i na koliko ostalih stranica ta stranica sadrži poveznice (nije isto ako je na cijeloj stranici samo jedna poveznica i ako na cijeloj stranici ima 1000 poveznica). Stranice na koje neka stranica M sadrži poveznice nazivamo *susjedima*.

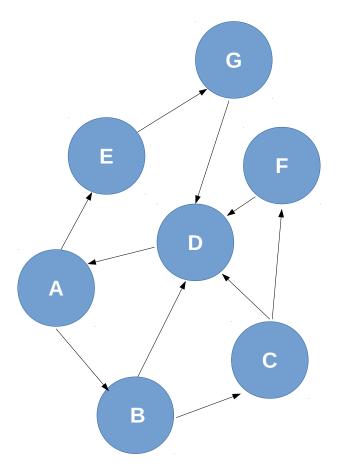
Pojednostavljena izvedba algoritma je sljedeća:

- 1. Početni rang svake stranice postavi se na 1.0.
- 2. Ponavljaj P puta:

- 2.1. Svaka stranica n svim svojim susjedima šalje doprinos rang (n) /brojSusjeda (n).
- 2.2. Postavi ukupni rang stranice prema formuli: 0.15+0.85*ukupan primljeni doprinos.

Kako bi se dobio što brže dobio što precizniji rezultat, važno je parametar ℙ postaviti na *ispravnu* vrijednost. U praksi je dovoljno ℙ postaviti na 10.

Pretpostavimo raspored stranica kao na slici 3.1.



Slika 3.1: Raspored susjeda u algoritmu

U nastavku je raspisan algoritam *PageRank* nad stranicama koje imaju susjede definirane kao na slici 3.1. Ako stranica N sadrži poveznicu na stranicu M to je na toj istoj slici definirano tako da strelica počinje iz kruga s oznakom N, a vrh joj pokazuje na krug s oznakom M.

Intuitivno se čini da bi stranica D trebala biti najviše rangirana budući da najviše stranica upućuje na nju. Idemo to provjeriti. Za početak, odredimo susjede od svake stranice i postavimo rang svake stranice na 1.0 kao što je prikazano u tablici 3.1.

Tablica 3.1: Inicijalizacija rangova i određivanje susjeda

Stranica	Rang	Susjedi
A	1.0	B, E
В	1.0	C
C	1.0	D, F
D	1.0	A
E	1.0	G
F	1.0	D
G	1.0	D

Sada se ponavljaju koraci 2.1 i 2.2 P puta. Ovdje je ponovljeno 2 puta i to bi trebalo biti dovoljno za razumjevanje algoritma. Iz koraka 2.1 računa se doprinos koja šalje svaka od stranica. Doprinos stranice A koji šalje drugima iznosi 1.0/2 = 0.5. Doprinos stranice B koji šalje drugima je 1.0/2 = 0.5. Doprinos stranice C jednak je kao i doprinos stranica A i B jer imaju jednak rang i broj susjeda. Doprinos stranica D, E, F i G iznosi 1.0/1 = 1.0. Rezultati za svaku od stranica prikazani su u tablici 3.2.

Tablica 3.2: Izračun doprinosa koji šalje svaka od stranica.

Stranica	Rang	Susjedi	Doprinos drugima
A	1.0	B, E	0.5
В	1.0	C, D	0.5
C	1.0	D, F	0.5
D	1.0	A	1.0
E	1.0	G	1.0
F	1.0	D	1.0
G	1.0	D	1.0

Sada, za svaku od stranica se računa ukupna suma koju je ta stranica dobila od svojih susjeda po formuli dana u koraku 2.2. Budući da je stranica A susjed samo od stranice D, ukupni primljeni doprinos koji je primila stranica A je upravo doprinos koji stranica D može dati drugima, a to je 1.0. Stranica B je susjed jedino stranici A i doprinos koji prima je upravo doprinos koji stranica A može u ovom trenutku dati drugima, a to je 0.5. Stranica C je susjed jedino stranici B i zbog toga je njen ukupni primljeni doprinos 0.5. Stranica D je susjed stranicama B, C, F i G pa je njen ukupni primljeni doprinos 0.5 + 0.5 + 1.0 + 1.0 = 3.0. Ukupan primljeni doprinos za svaku od stranica nalazi se u tablici 3.3.

Tablica 3.3: Ukupni primljeni doprinos svake od stranica.

Stranica	Rang	Susjedi	Doprinos drugima	Ukupni primljeni doprinos
A	1.0	B, E	0.5	1.0
В	1.0	C, D	0.5	0.5
C	1.0	D, F	0.5	0.5
D	1.0	A	1.0	3.0
E	1.0	G	1.0	0.5
F	1.0	D	1.0	0.5
G	1.0	D	1.0	1.0

Nakon što je izračunat ukupni primljeni doprinos, vrijeme je za ponovni izračun ranga svake od stanica po formuli koja se nalazi u koraku 2.2. Novi rang stranice A iznosi 0.15+0.85*1.0=1.0. Novi rang stanice B iznosi 0.15+0.85*0.5=0.575. Novi rang stranice C iznosi isto 0.575 jer stranica C i stranica B imaju jednaki ukupni primljeni doprinos. Novi rang stranice D je 0.15+0.85*3.0=2.7. Nakon što se izračuna i postavi novi rang za svaku od stranica, nastupi situacija kao u tablici 3.4

Tablica 3.4: Rang svake od stranica nakon prve iteracije.

Stranica	Rang	Susjedi
A	1.0	B, E
В	0.575	C, D
C	0.575	D, F
D	2.7	A
E	0.575	G
F	0.575	D
G	1.0	D

Vidimo da je već u prvoj iteraciji algoritma stranica D iskočila sa svojim rangom od okoline. Ovo smo bili i pretpostavili budući da je stranica D susjed najvećem broju stranica, odnosno najveći broj stranica sadrži poveznicu na stranicu D.

Idemo napraviti još jednu iteraciju i vidjeti što će se dogoditi s rangovima.

Iz tablice 3.4 dohvaćamo rang i broj susjeda svake od stranica te računamo doprinos koji svaka od stranica može dati svojim susjedima prema već spomenutoj formuli u gornjem algoritmu u koraku 2.1. Doprinos koji stranica A šalje drugima iznosi 1.0/2 = 0.5. Doprinos koji stranica B šalje je 0.575/2 = 0.2875. Doprinos stranice C je jednak

doprinosu stranice B budući da imaju jednak rang i broj susjeda. Doprinos stranice D iznosi 2.7/1 = 2.7. Doprinos stranica E i F iznosi 0.575, a doprinos stranice G je 1.0. Rezultati izračuna koliko koja stranica doprinosi drugima prikazani su u tablici 3.5.

Tablica 3.5: Izračun doprinosa koji šalje svaka od stranica u drugoj iteraciji.

Stranica	Rang	Susjedi	Doprinos drugima
A	1.0	B, E	0.5
В	0.575	C, D	0.2875
C	0.575	D, F	0.2875
D	2.7	A	2.7
E	0.575	G	0.575
F	0.575	D	0.575
G	1.0	D	1.0

Sada se ponovno računa ukupni primljeni doprinos svake od stranica. Tako za stranicu A se dobije da ukupni primljeni doprinos iznosi 2.7 jer je ona jedino susjed stranici D. Ukupni primljeni doprinos stranice B je 0.5 jer je upravo to iznos koliko stranica A doprinosi drugima, a stranica B je jedino susjed od stranice A. Stranica C ima ukupni primljeni doprinos 0.2875 jer je upravo to iznos doprinosa stranice B, a stranica C je susjed jedino stranici B. Stranica D prima zbroj doprinosa svih stranica kojima je susjed odnosno zbroj doprinosa stranica B, C, F i G. Iz toga proizlazi da je ukupni primljeni doprinos stranice D 0.2875 + 0.2875 + 0.575 + 1.0 = 2.15. Ukupni primljeni doprinos za svaku od stranica nalazi se u tablici 3.6

Tablica 3.6: Ukupni primljeni doprinos svake od stranica u drugoj tablici.

Stranica	Rang	Susjedi	Doprinos drugima	Ukupni primljeni doprinos
A	1.0	B, E	0.5	2.7
В	0.575	C, D	0.2875	0.5
C	0.575	D, F	0.2875	0.2875
D	2.7	A	2.7	2.15
E	0.575	G	0.575	0.5
F	0.575	D	0.575	0.2875
G	1.0	D	1.0	0.575

Nakon što je i u drugoj iteraciji izračunat ukupni primljeni doprinos, vrijeme je za ponovni izračun ranga svake od stanica po formuli koja se nalazi u koraku 2.2.

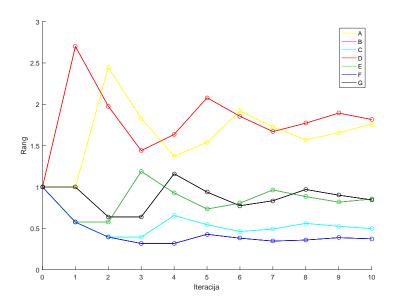
Novi rang stranice A iznosi 0.15+0.85*2.7=2.445. Novi rang stanice B iznosi 0.15+0.85*0.5=0.575. Novi rang stranice C iznosi 0.15+0.85*0.2875=0.394375. Novi rang stranice D je 0.15+0.85*2.15=1.9775. Rang stranice E je 0.15+0.85*0.5=0.575, a rang stranice F iznosi 0.15+0.85*0.2875=0.394375. Konačno, rang stranice G je 0.15+0.85*0.575=0.63875. Nakon što se postavi novi rang za svaku od stranica, nastupi situacija kao u tablici 3.7

Tablica 3.7: Rang svake od stranica nakon prve iteracije.

Stranica	Rang	Susjedi
A	2.445	B, E
В	0.575	C, D
C	0.394375	D, F
D	1.9775	A
E	0.575	G
F	0.394375	D
G	0.63875	D

Iz tablice 3.7 vidljivo je da je stranica A preuzela vodstvo. To se isto može intuitivno prihvatiti budući da skoro sve stranice pokazuju na stranicu D, a upravo D je jedina stranica koja pokazuje na A.

Nakon što se izvrti 10 iteracija, stvari se stabiliziraju. Graf koji opisuje kako se rangovi mijenjaju kroz 10 iteracija prikazan je slikom 3.2.



Slika 3.2: Vrijednosti ranga ovisno o iteraciji

3.1.2. Implementacija i analiza

Kada je poznato kako "ručno" radi algoritam, ne bi trebao biti problem napisati programsku implementaciju koja se nalazi u primjeru 3.1. U ovom dijelu je osim samog koda napisana i detaljna analiza tog koda kako bi se dobilo što više informacija o tome kako radi tehnologija *Apache Spark*.

```
package hr.fer.zemris.naprednoProgramiranje;
  import java.util.ArrayList;
  import java.util.List;
  import org.apache.spark.SparkConf;
  import org.apache.spark.api.java.JavaPairRDD;
  import org.apache.spark.api.java.JavaRDD;
  import org.apache.spark.api.java.JavaSparkContext;
  import com.google.common.collect.Iterables;
12
  import scala.Tuple2;
  /**
15
   * Program računa rang pojedine stranice.
   * Očekuje se da svaki redak ulazne datoteke sadrži
   * samo 2 stranice u formatu "StranicaA StranicaB", a taj
   * zapis predstavlja da je StranicaB susjed od StranicaA.
20
   * @author mmatak
22
   */
  public class AlgoritamPageRank {
    private static final String ULAZNA_DATOTEKA =
        "pageRankInput.txt";
    private static final int BROJ_ITERACIJA = 10;
26
    public static void main(String[] args) {
       // Inicijalizacija SparkContext-a.
       SparkConf conf = new SparkConf().setMaster("local")
```

```
.setAppName("Algoritam PageRank");
       JavaSparkContext sc = new JavaSparkContext(conf);
33
       // Učitavanje podataka.
       JavaRDD<String> ulaz = sc.textFile(ULAZNA_DATOTEKA);
       // Pročitaj sve ulazne URL-e i inicijaliziraj njihove
          susjede.
       JavaPairRDD<String, Iterable<String>> linkovi =
          ulaz.mapToPair(
           redak -> {
39
              String[] elementi = redak.split("\\s+");
              return new Tuple2<String, String>(elementi[0],
                 elementi[1]);
            }).distinct().groupByKey().cache();
42
       // Svako ime susjeda zamijeni s 1.0 i vrati novi skup
          podataka.
       JavaPairRDD<String, Double> rangovi =
44
          linkovi.mapValues(value -> 1.0);
45
       // iteracija 2. i 3. koraka algoritma
       for (int i = 0; i < BROJ_ITERACIJA; i++) {</pre>
         // za svaki link izracunaj njegovu doprinos drugim
            linkovima
         JavaPairRDD<String, Double> doprinosi =
49
         linkovi.join(rangovi).values().flatMapToPair(
            linkoviRang -> {
              int brojSusjeda = Iterables.size(linkoviRang._1);
              List<Tuple2<String, Double>> rezultati = new
                 ArrayList<Tuple2<String, Double>>();
55
                for (String susjed : linkoviRang._1) {
                  rezultati.add(new Tuple2<String, Double>(
                   susjed, linkoviRang._2 / brojSusjeda));
                return rezultati;
```

```
}
          );
63
          rangovi = doprinosi.reduceByKey((v1, v2) -> v1 + v2)
64
               .mapValues(suma \rightarrow 0.15 + suma * 0.85);
       }
       // spremi u memoriju
67
       List<Tuple2<String, Double>> rangoviFinal =
           rangovi.collect();
       // ispis
69
       for (Tuple2<String, Double> entry : rangoviFinal) {
70
          System.out.printf("Stranica %s ima rang %.2f\n",
             entry._1, entry._2);
       }
       sc.close();
     }
74
```

Primjer 3.1: Algoritam *PageRank*.

Analizirajmo kod naveden u primjeru 3.1.

Od linije 30 do linije 32 inicijalizira se glavno računalo i ime aplikacije. Ovdje je glavno računalo postavljeno na local budući da se aplikacija odvija na lokalnom računalu, a ne na grozdu. Ime aplikacije postavljeno je na temelju algoritma kojeg aplikacija implementira.

Linija 35 obavlja inicijalizaciju *otpornog raspodijeljenog skupa podataka* čitajući podatke iz datoteke čija je putanja zadana varijablom ULAZNA_DATOTEKA.

Od linije 38 do linije 42 obavlja se pridruživanje susjeda svakoj stranici. Svaki se redak iz skupa ulaz podijeli na dva elementa - element prije i element poslije razmaka. Ta dva elementa predstavljaju uređeni par (ključ, vrijednost) gdje je stranica koja je prije razmaka ključ, a stranica nakon razmaka vrijednost. To znači da je stranica vrijednost susjed od stranice ključ. Budući da su dozvoljeni duplikati u ulaznom skupu podataka tj. može postojati dva identična retka koja govore kako stranica N ima susjeda M, to se mora uzeti u obzir. Za rangiranje stranice nije bitno koliko poveznica stranica N sadrži na stranicu M. U ovoj implementaciji, svejedno je radi li se o 1 ili 1000 poveznica jer su to sve iste poveznice. Da bi se osiguralo da ne postoji niti jedan duplikat, poziva se metoda distinct (). Pozivom metode groupByKey () obavlja se spajanje uređenih parova s istim ključem, a njihove vrijednosti spremamo u listu.

Primjerice, postoje li kolekcija uređenih parova (A, B), (A, C), (A, D) i nad tom kolekcijom pozove se groupByKey () rezultat će biti uređeni par $(A, \{B, C, D\})$. *Vrijednost* tog uređenog para je iterabilna (implementira sučelje Iterable) i zbog toga je povratna vrijednost u obliku JavaPairRDD<String, Iterable<String>>. Rezultat je skup podataka linkovi predstavljen uređenim parovima gdje su *ključevi* stranice, a *vrijednosti* susjedi tih stranica. Konačno, kako se ne bi ovo moralo svaki puta ispočetka računati, rezultat se pohranjuje u memoriju pozivom metode cache ().

Linija 44 iz skupa podataka linkovi "provuče" svaku od *vrijednosti* (čitava kolekcija je zapravo jedna *vrijednost*) kroz funkciju koja tu čitavu kolekciju samo preslika u *vrijednost* 1.0. Sada je nastao novi skup uređenih parova koji za *ključ* imaju stranicu, a za *vrijednost* 1.0. Ovim postupkom je zapravo postavljen rang svake stranice na početnu vrijednost.

Poziv naredbe linkovi. join (rangovi) u liniji 50 vraća novi skup podataka koji kao ključeve ima ključeve iz skupova linkovi i rangovi (bez dupliciranja), a odgovarajuće vrijednosti su uređeni parovi vrijednosti iz tih skupova. Preciznije rečeno, join (drugiSkupPodataka) ako je pozvan nad skupovima uređenih parova oblika (K,V) i (K,W) kao rezultat vraća skup podataka uređenih parova oblika (K,V)W)). Ukoliko postoje različiti ključevi u skupovima podataka nad kojima se izvršava join (), parovi s stim ključem su ignorirani. Jedino se "uparuju" uređeni parovi s istim ključem. Metoda values () vraća skup svih vrijednosti iz skupa podataka dobivenog pozivom metode join(). U ovom primjeru metoda values() vraća skup uređenih parova gdje je ključ kolekcija susjeda neke stranice, a vrijednost rang te stranice. Metoda flatMapToPair() kao argument prima funkciju koja implementira sučelje PairFlatMapFunction<T, K2, V2>. Ta funkcija prima element tipa T i vraća nula ili više uređenih parova oblika (K2, V2). Metoda flatMapToPair() zapravo "provuče" svaki element skupa nad kojim je pozvana kroz funkciju koju primi kao argument i na kraju, na temelju uređenih parova koje je ta funkcija vratila, kreira skup podataka oblika (K2, V2). Element koji se "provlači" imenovan je varijablom linkoviRang.

Od linije 51 do linije 61 obrađuju se podatci koji su predstavljeni uređenim parovima oblika (*ključ*, *vrijednost*) gdje je *ključ* kolekcija susjeda neke stranice, a *vrijednost* rang te stranice.

Linija 53 zapravo dohvaća veličinu kolekcije koja je predstavljena *ključem*, odnosno varijablu brojSusjeda postavlja na onu vrijednost koliko stranica koja se trenutno obrađuje ima susjeda.

Od linije 56 do linije 59 proteže se petlja koja u listu rezultati sprema uređene

parove oblika (*ključ*, *vrijednost*) gdje je *ključ* susjed, a *vrijednost* doprinos stranice koja se trenutno obrađuje tom susjedu.

Funkcija flatMapToPair() spaja sve vraćene rezultate u jedan skup i sada se u skupu podataka doprinosi nalaze uređeni parovi gdje je *ključ* stranica, a *vrijednost* doprinos neke stranice toj stranici. Budući da neka stranica ne mora biti susjed samo jednoj stranici, u tom skupu podataka se može naći više parova s istim ključem - svaka vrijednost je doprinos od neke druge stranice.

Linija 64 "spaja" sve parove s istim *ključem* tako što od više uređenih parova s istim *ključem* stvori jedan uređeni par s tim *ključem*, a *vrijednosti* zbroji. Time je zapravo izračunat ukupni primljeni doprinos svake od stranica i nastao je novi skup uređenih parova oblika (*stranica*, *ukupni primljeni doprinos*).

Linija 65 dohvaća *vrijednosti* iz tih uređenih parova i na temelju njih računa nove *vrijednosti* i postavlja ih kao trenutne *vrijednosti*. Nove *vrijednosti* su zapravo novi rangovi svake od stranica. Sada se u varijabi rangovi nalaze uređeni parovi (*stranica*, *rang*).

Postupak od linije 47 do linije 66 ponavljamo potrebni broj puta kako bi se rang svake od stanica postavio na što ispravniju vrijednost. Kao što je već rečeno, u praksi je to desetak puta pa je tako i u ovom primjeru.

Kada su izračunati rangovi svake od stanica, sve što još treba je ispisati podatke. Kako bi se uštedilo na vremenu (ponovno računanje rangova svaki puta kada treba raditi nešto s tim rangovima), dohvaćamo sve podatke iz skupa podataka rezultati i spremamo ih u varijablu rezultatiFinal. Taj dio je prikazan linijom 68.

Konačno, u for petlji iteriramo po elementima liste rezultatiFinal te ispišemo ime i rang stranice. Na kraju zatvorimo *SparkContext*.

3.2. Skupovi podataka kao uređeni parovi

U primjeru 3.1 već je uveden pojam skupa podataka koji je predstavljen uređenim parom (ključ, vrijednost). U ovoj tehnologiji takav skup podataka nije rijetkost i zbog toga postoji niz transformacija nad upravo tim oblikom skupa podataka, a neke od njih su već objašnjene u potpoglavlju 3.1.2. Osnovne informacije mogu se pronaći u tablicama 3.8 i 3.9, a za više informacija, konzultirati službenu dokumentaciju http://spark.apache.org/docs/latest/api/java/index.html?org/apache/spark/api/java/JavaPairRDD.html.

Često postoji potreba za transformacijom koja je kombinacija dva skupa podataka. Primjerice, spajanje tablica iz baze podataka. Te stvari su moguće i ovdje, a samo neke

Tablica 3.8: Neke od transformacija nad jednim skupom podataka koji predstavljen uređenim parovima. Primjer: $\{(1, 2), (3, 4), (3, 6)\}$.

Transformacija	Opis	Primjer korištenja	Rezultat
reduceByKey(func)	Kombinira vri-	rdd.reduceByKey((x,y)	{(1, 2),
	jednosti s istim	$\rightarrow x + y$	(3, 10)
	ključem.		
groupByKey()	Grupira vrijed-	rdd.groupByKey()	{(1, [2]),
	nosti s istim		(3, [4,
	ključem.		6])}
<pre>mapValues(func)</pre>	Primjena funkcije	rdd.mapValues({(1, 12),
	nad svakom	x -> x + 10	(3, 14),
	<i>vrijednosti</i> u		(3, 16)
	uređenom paru,		
	ključ ostaje		
	nepromijenjen.		
keys()	Vraća novi skup	rdd.keys()	$\{1, 3, 3\}$
	podataka koji se		
	sastoji od svih		
	ključeva.		
values()	Vraća novi skup	rdd.values()	$\{2, 4, 6\}$
	podataka koji se		
	sastoji od svih		
	vrijednosti.		

od transformacija prikazane su u tablici 3.9. Osim transformacija, postoje i akcije koje je moguće izvoditi nad otpornim raspodijeljenim skupom podataka koji je predstavljen kao uređeni par, ali radi formata ovog rada, nije napisana još jedna tablica gdje bi te akcije bile objašnjene. Za informacije o akcijama, konzultirati [1].

Ono što je još često potrebno, a nije već spomenuto jest sortiranje podataka. Tehnologija *Apache Spark* omogućuje i sortiranje uređenih parova po *ključu*. Transformacija se naziva sortByKey i primjer poziva je rdd. sortByKey (). Prima argument treba li sortirati uzlazno (podrazumijevana vrijednost) ili silazno. Dodatno, moguće je i predati komparator koji će usporediti ključeve.

Tablica 3.9: Neke od transformacija nad dva skupa podataka koji su predstavljeni uređenim parovima. Primjer: rdd = (1, 2), (3, 4), (3, 6), drugi = (3,9).

Transformacija	Opis	Primjer korištenja	Rezultat
subtractByKey	Briše parove	rdd.subtractByKey(drug	i) {(1, 2)}
	koji imaju iste		
	ključeve.		
join	Obavlja operaciju	rdd.join(drugi)	{(3, (4,
	prirodnog spa-		9)), (3,
	janja (engl. inner		(6, 9))
	join)		

3.3. Čitanje i spremanje podataka

U ranijim primjerima prikazano je kako ostvariti čitanje podataka iz tekstualne datoteke kao i kako zapisati rezultat u neku tekstualnu datoteku. Neki od podržanih oblika tekstualnih datoteka su JSON, CSV i TSV oblik. Tehnologija *Apache Spark* omogućuje i puno više. Između ostalog, moguće je čitati i pisati direktno u bazu podataka (Cassandra, HBase, Elasticsearch, JDBC), strukturirane izvore uključujući JSON i Apache Hive, a isto tako moguće je čitati i podatke koji su spremljeni na raspodijeljenom sustavu datoteka poput NFS, HDFS ili Amazon S3.

Datoteke u JSON obliku se učitaju poput tekstualne datoteke, a zatim se parsira JSON format. Za parsiranje JSON formata se u pravilu koriste gotove biblioteke, a popularna biblioteka za Javu naziva se *Jackson*. Više informacija o tim bibliotekama može se pronaći na http://geokoder.com/java-json-libraries-comparison.

Više informacija o čitanju i spremanju podataka potražiti u poglavlju *Loading and saving your data*[2].

3.4. Dijeljene varijable

Funkcija koju predamo metodi map () vidi varijable koje su definirane u *pozivajućem* programu, ali svaki zadatak (engl. task) koji se vrti na grozdu dobije svoju kopiju vrijednosti tih varijabli, a nove vrijednosti tih varijabli nisu propagirane pozivajućem programu. Riješenje ovog problema su dijeljene varijable (engl. shared variables). Ime su dobile po tome što je njihova ispravna vrijednost vidljiva svuda u grozdu.

3.4.1. Odašiljatelji

Ukoliko je potrebno dohvaćati vrijednost neke varijable na cijelom grozdu, potrebna je varijabla odašiljatelj (engl. broadcast variable). Ta varijabla se pohranjuje u memoriji i zbog toga ne smije zauzimati puno prostora. Također, takva varijabla je nepromjenjiva (engl. immutable). Moguće je slati i promjenjivu varijablu, ali ta promjena će biti jedino vidljiva na tom čvoru koji je promjenu napravio, a takvo ponašanje u pravilu nije poželjno.

Kao što je navedeno u [1], *odašiljatelji* se mogu koristiti kao statičke lookup tablice (engl. *lookup table*). Pretpostavimo da radimo na aplikaciji koja u bazi ima dvije tablice, tablicu koja pamti identifikator i ime naselja te tablicu koja pamti identifikator korisnika koji se prijavio i identifikator naselja gdje se prijavio. Primjer takvih tablica su tablice 3.10 i 3.11.

Tablica 3.10: Tablica naselja.

id	ime
1	Centar
2	Maksimir
3	Jordanovac
4	Siget
5	Dubrava

Zadatak je saznati ime naselje za svaku od prijava. Pretpostavka je da postoji jako puno prijava, a ne previše naselja tj. prijave su u nekoj velikoj tablici, a naselja su u maloj tablici. Pri obavljanju klasične transformacije join, podatci obje tablice bi putovali svuda po mreži i to bi uzelo puno vremena i mrežnih resursa. Ukoliko je potrebno napraviti join male i velike tablice, bolje rješenje je malu tablicu (koja stane u memoriju i ne mijenja se) postaviti kao varijablu *odašiljatelj*. Na taj način, jedino će mala tablica putovati preko mreže. U ovom primjeru, mala tablica je tablica naselja 3.10, a velika tablica je tablica prijave 3.11.

Varijable koje su postavljene kao *odašiljatelj* preko mreže se prenose bittorent protokolom. To znači da što više čvorova treba tu varijablu, ta varijabla se brže širi po mreži¹.

package hr.fer.zemris.naprednoProgramiranje;

¹Više informacija o bittorent protokolu na stranici http://www.bittorrent.org/

```
import java.util.Map;
  import org.apache.spark.SparkConf;
  import org.apache.spark.api.java.JavaPairRDD;
  import org.apache.spark.api.java.JavaSparkContext;
  import org.apache.spark.broadcast.Broadcast;
  import scala.Tuple2;
  public class Primjer5 {
    public static void main(String[] args) {
       // Inicijalizacija SparkContext-a.
14
       SparkConf conf = new SparkConf().setMaster("local")
            .setAppName("Razasiljane varijable");
       try (JavaSparkContext sc = new JavaSparkContext(conf)) {
18
10
         // inicijalizacija naselja
         JavaPairRDD<String, String> naseljaRDD = sc
21
            .textFile("tblNaselja.txt").mapToPair(
              redakTablice -> {
                String[] redak = redakTablice.split(",");
                return new Tuple2<String, String>(redak[0],
25
                   redak[1]);
              });
         // prijave
         JavaPairRDD<String, String> prijaveRDD = sc
              .textFile("tblPrijave.txt").mapToPair(redakTablice
                String[] redak = redakTablice.split(",");
                return new Tuple2<String, String>(redak[0],
                   redak[1]);
              });
33
         // odasiljanje read only varijable "naselja" kroz grozd
         final Broadcast<Map<String, String>> naselja = sc
```

```
.broadcast(naseljaRDD.collectAsMap());
          JavaPairRDD<String, Tuple2<String, String>>
40
             imenovanePrijave = prijaveRDD
               .mapToPair(
41
                 prijava -> new Tuple2<String, Tuple2<String,</pre>
42
                    String>>(
                      prijava._1,
43
                      new Tuple2<String, String>(
44
                        prijava._2,
45
                        naselja.getValue().get(prijava._2)
47
                    )
48
                 );
          //ispis
          for (Tuple2<String, Tuple2<String, String>> element :
51
             imenovanePrijave
               .collect()) {
            System.out.printf("Id prijave: %s \t Ime naselja:
53
                %s\n",
                 element._1, element._2._2);
57
```

Primjer 3.2: Korištenje odašiljatelja.

U primjeru 3.2 pokazano je korištenje odašiljatelja. Osim toga, u tom primjeru je *SparkContext* inicijaliziran u *try-catch* bloku naredbi. Budući da *SparkContext* implementira sučelje Closeable, to je garancija da ako ga otvorimo *try-catch* inicijalizacijskom bloku da će biti i pravovremeno zatvoren.

Program čita iz datoteke tblNaselja.txt podatke o naseljima koji su zapisani u obliku *id_naselja*, *ime_naselja*. Podatci o prijavama imaju oblik *id_prijave*, *id_naselja* i čitaju se iz datoteke tblPrijave.txt. Podatci u tim datotekama jednaki su podatcima iz tablica 3.10 i 3.11. Nakon što su podatci učitani, kreirani su skupovi po-

dataka. Zatim se skup podataka koji predstavlja tablicu 3.10 pretvorio u mapu gdje je *ključ* identifikator naselja, a *vrijednost* ime naselja. Takva mapa je *odaslana* svuda po mreži.

Tablica 3.11: Tablica prijave.

id korisnik	id_naselje
112312	1
	1
243242	2
254331	2
432115	1
567893	4
537893	4

Nakon toga, za svaku prijavu, kreiran je novi uređeni par koji za *ključ* ima identifikator prijave, a za vrijednost objekt Tuple2 koji za prvu vrijednost ima identifikator nasilja, a za drugu vrijednost ime tog naselja. Razred Tuple2 preuzet je iz programskog jezika Scala i predstavlja uređeni par (*vrijednost_1*, *vrijednost_2*). Shodno tome, prvoj vrijednosti se pristupa preko element._1, a drugoj vrijednost preko element._2.

Na kraju su ispisani svi dobiveni podatci, a rezultat je prikazan u primjeru 3.3.

```
Id prijave: 112312 Ime naselja: Centar
Id prijave: 243242 Ime naselja: Maksimir
Id prijave: 254331 Ime naselja: Maksimir
Id prijave: 432115 Ime naselja: Centar
Id prijave: 567893 Ime naselja: Siget
Id prijave: 537893 Ime naselja: Siget
```

Primjer 3.3: Identifikatori prijave i imena naselja odakle su prijave poslane.

3.4.2. Akumulatori

Ako se odašiljatelje gleda kao globalne *gettere*, *akumulatore* (engl. *accumulators*) se može gledati kao na globalne *settere*. Za razliku od odašiljatelja koji svim čvorovima dojavljuju vrijednost, akumulatori akumuliraju, odnosno dohvaćaju vrijednost svakog čvora. Ideja je jednostavna, ako je potrebno s iz više radnih čvorova mijenjati nekakvu globalnu varijablu, ta varijabla se postavi kao akumulator.

U datoteci log.txt pohranjeni su zapisi pristupanju na server. Svaki zapis je u novom retku. Ukoliko u nekom retku postoji riječ error, taj zapis nije valjan. Svaki drugi zapis je valjan. Zadatak je izbrojati koliko postoji valjanih zapisa i koliko postoji zapisa koji nisu valjani. Jedno od riješenja je koristiti dva akumulatora: jedan za valjane zapise i drugi za zapise koji nisu valjani. Programska implementacija tog rješenja dana je u primjeru 3.4.

```
package hr.fer.zemris.naprednoProgramiranje;
  import org.apache.spark.Accumulator;
  import org.apache.spark.SparkConf;
  import org.apache.spark.api.java.JavaRDD;
  import org.apache.spark.api.java.JavaSparkContext;
  public class Primjer6 {
    public static void main(String[] args) {
       SparkConf conf = new SparkConf().setMaster("local")
            .setAppName("Koristenje akumulatora");
       try (JavaSparkContext sc = new JavaSparkContext(conf)) {
12
         // inicijalizacija naselja
         JavaRDD<String> zapisi = sc.textFile("log.txt");
         // inicijalizacija akumulatora
16
         Accumulator<Integer> valjaniZapisi = sc.accumulator(0);
         Accumulator<Integer> neValjaniZapisi =
            sc.accumulator(0);
         // obrada podataka
         for (String redak : zapisi.collect()) {
            if (redak.contains("error")) {
              neValjaniZapisi.add(1);
23
            } else {
              valjaniZapisi.add(1);
            }
         // ispis rezultata
         System.out.printf("Valjanih zapisa ima %d\n",
29
              valjaniZapisi.value());
30
```

```
System.out.printf("Nevaljanih zapisa ima %d\n",
neValjaniZapisi.value());
}

}

}
```

Primjer 3.4: Korištenje akumulatora.

Primjer 3.4 učita novi skup podataka, inicijalizira akumulatore te za svaki redak, ovisno sadrži li redak riječ *error* ili ne, poveća vrijednost odgovarajućeg akumulatora.

U primjeru 3.4 korišteni su cjelobrojni akumulatori. Osim *Integer* tipa podataka, postoje akumulatori i za *Long*, *Double* te *Float* tip podataka. Ukoliko je potrebno, moguće je kreirati i akumulator za svoj vlastiti tip podataka. Za više informacija, konzultirati http://www.programcreek.com/java-api-examples/index.php?api=org.apache.spark.Accumulator.

4. Zaključak

Zaključak.

LITERATURA

- [1] Službena dokumentacija projekta *Apache Spark* http://spark.apache.org/docs/latest/, posjećeno 1.5.2016
- [2] Holden Karau, Andy Konwinski, Patrick Wendell i Matei Zaharia *Learning Spark*, *lighting-fast*, O'Reilly 2015.
- [3] Marko Čupić, Programiranje u Javi, verzija 0.3.26
- [4] Matei Zaharia, Mosharaf Chowdhury, Michael J. Franklin, Scott Shenker, Ion Stoica, *Spark: Cluster Computing with Working Sets*, University of California, Berkeley

Appendices

A. Instalacija

Ovdje će biti prikazana instalacija na operacijskom sustavu *Ubuntu 15.10*. Ovo nije veliko ograničenje jer se iz ovih uputa može zaključiti i kako instalacija ide za neki drugi operacijski sustav.

Za početak je potrebno imati instaliranu Javu, a je li Java instalirana na računalu se može provjeriti tako što se u naredbenom retku unese sljedeća naredba:

java -version. Kao rezultat bi trebali dobiti trenutno instaliranu verziju Jave. Ukoliko Java nije instalirana, potrebno ju je najprije instalirati. Više informacija o instalaciji se može pronaći u [3].

Jednom kada imamo instaliranu Javu, sve što treba napraviti je otići na službene stranice: https://spark.apache.org/downloads.html, odabrati najnoviju verziju (Za vrijeme pisanja ovog rada to je verzija 1.6.1 (Mar 09 2016), izabrati odgovarajući paket te pokrenuti dohvaćanje odgovarajuće .tgz arhive. Najjednostavnije je odabrati neki pre-built paket, primjerice Pre-built for Hadoop 2.6 and later. Daljnji koraci instalacije su napisani pod pretpostavkom da je dohvaćena ta verzija paketa. Moguće je instalirati i Source code varijantu paketa, ali taj postupak instalacije ovdje nije opisan.

Nakon što je dohvaćena odgovarajuća arhivu, potrebno ju je raspakirati.

Raspakiranje arhive moguće je napraviti preko naredbe:

```
$ tar -xvf spark-1.6.1-bin-hadoop2.6.tgz
```

Nakon toga, dobra je praksa premjestiti instalaciju u neki prikladniji direktorij. Tako nešto može se napraviti na sljedeći način:

```
$ mv Downloads/spark-1.6.1-bin-hadoop2.6 faks/spark/
```

Ovim korakom je instalacija završena.

Kako bi bili sigurni da je instalacija uspješna, potrebno je pozicionirati se u *bin* direktorij te u terminalu upisati ./spark-shell. Ispis bi trebao biti sličan ovome:

Ukoliko se prikaže greška vezana uz *sqlContext*, to nije razlog za brigu. U ovom trenutku to nije važno. Radi ljepšeg formata ovog rada, u gornjem ispisu izbrisana su upozorenja (engl. *warnings*).

B. Postavljanje datoteke pom.xml

Datoteka koja je potrebna kako bi Maven ispravno dohvatio artifakt spark-core bi trebala izgledati slično kao što je dano u nastavku. Za ispravno funkcioniranje, trebala bi se zvati pom.xml.

```
project xmlns="http://maven.apache.org/POM/4.0.0"
   xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
  xsi:schemaLocation="http://maven.apache.org/POM/4.0.0
  http://maven.apache.org/xsd/maven-4.0.0.xsd">
 <modelVersion>4.0.0</modelVersion>
 <groupId>hr.fer.zemris
 <artifactId>Prvi-programi</artifactId>
 <version>0.0.1-SNAPSHOT
 <name>Prvi programi</name>
 <description>Prvi programi u Spark-u</description>
 <dependencies>
  <dependency>
    <groupId>org.apache.spark</groupId>
    <artifactId>spark-core 2.10</artifactId>
    <version>1.6.1
  </dependency>
 </dependencies>
</project>
```

Obrada podataka tehnologijom Apache Spark

Sažetak

Sažetak na hrvatskom jeziku.

Ključne riječi: Ključne riječi, odvojene zarezima.

Title

Abstract

Abstract.

Keywords: Keywords.